

تقرير التحسينات النهائية

تحليل النظام الهجين وعتبات الثقة — وحزمة المراجعة المستقلة

مشروع: فرز المخلفات بالذكاء الاصطناعي — MobileNetV2 مقابل Gemini Vision

(ملحق تقني لمسابقة بحث: تدوير المخلفات وإعادة استخدامها)

إعداد الطالبة: [الاسم الثلاثي]

أكتوبر 2026

ملخص تنفيذي

بناءً على طلب مراجعة نقاط الضعف المحتملة، نُفذت أربعة تحسينات كاملة باستخدام البيانات الحقيقية الموجودة فقط — من دون أي طلب جديد لـ Gemini أو أي أرقام مصنعة:

1. تحليل النظام الهجين الحقيقي: سياسة «MobileNet محلياً أولاً، تصعيد لـ Gemini عند الثقة المنخفضة» حُسبت فعلياً على الـ 125 صورة من ملفي التنبؤات الموجودين.
 2. تحليل معايير الثقة: هل ثقة MobileNet تميز الإجابة الصحيحة من الخاطئة على الصور غير المقيدة؟
 3. المرئيات الجديدة: شكل سلسلة القيمة (ربط البحث بموضوع المسابقة) + مخطط المفاضلة (دقة/زمن/خصوصية).
 4. حزمة المراجعة الثانية: بروتوكول مراجعة عمياء كامل جاهز للتنفيذ (125 صورة مرقمة بترتيب مخلوط + ورقة قرارات + تعريفات الفئات).
- والبندين المعلقين موثقين بأدواتهما الجاهزة: المراجعة الثانية (تنتظر مُقيماً بشرياً — والبروتوكول جاهز) والاستبيان المصغر (النموذج جاهز والتنفيذ يتطلب وصولاً للطلاب).

(1) تحليل الثقة والنظام الهجين الحقيقي

1-1 المنهج: تحليل استكشافي بعدي لعتبات التصعيد


التصنيف المنهجي: هذا تحليل استكشافي بعدي على مجموعة الاختبار ذاتها؛ العتبات فُحصت بعد ظهور نتائج التقييم، وهو ليس تحقّقاً مستقلاً ولا سياسة جاهزة للنشر، ولا يدخل البحث الأساسي — يبقى في تقرير التحسينات والمستودع فقط.

السياسة: إذا كانت ثقة MobileNet في توقعها $T \leq$ تُقبل الإجابة محلياً؛ وإلا تُصعّد الصورة إلى Gemini وتُستخدم إجابة Gemini الحقيقية المسجلة في التجربة (results/webset/predictions_gemini_webset.csv). لا محاكاة مصنعة ولا طلبات جديدة — ربط مباشر بين ملفي التنبؤات الفعليين على نفس الـ 125 صورة (تحقق التغطية والوسوم قبل الحساب).

1-2 النتائج الفعلية عند كل عتبة

العتبة T	تصعيد Gemini	نسبة التصعيد	دقة النظام المجهين
0.50	45	36.0%	0.5520
0.60	63	50.4%	0.6640
0.70	73	58.4%	0.7200
0.80	89	71.2%	0.7760
0.90	102	81.6%	0.8160
0.95	111	88.8%	0.8480 (الأفضل)

للمرجعية: MobileNet وحده = 0.3200 — Gemini وحده = 0.8880.




شكل (1-1): منحني سياسة التصعيد مقابل العتبتين المرجعيتين

1-3 معايرة الثقة: هل الثقة تميز الصحيح من الخاطئ؟

المؤشر	القيمة الفعلية
متوسط الثقة عندما يكون التوقع صحيحًا	0.7190
متوسط الثقة عندما يكون التوقع خاطئًا	0.5971

شريحة الثقة	عدد الصور	الدقة الفعلية داخل الشريحة
0.70 – 0.50	28	0.1786
0.85 – 0.70	23	0.3913
0.95 – 0.85	15	0.3333
1.00 – 0.95	14	0.6429



شكل (1-2): معايرة الثقة

4-1 التفصيل عند أفضل عتبة ($T = 0.95$)


النظام الهجين	MobileNet وحدة	العدد	المجموعة الفرعية
0.9091	0.3864	44	مشاهد مفردة
0.8148	0.2840	81	مشاهد مزدوجة
0.8468	0.3333	111	مواد عادية
0.8571	0.2143	14	مواد شفافة صعبة

5-1 القراءة الصادقة للنتائج


1. النظام المهجين يضاعف الدقة تقريبًا: من 32.00% إلى 77.6% عند عتبة 0.80 — التحسين حقيقي ومقاس.
2. لكنه لا يبلغ Gemini وحده (88.80%) مهما رفعت العتبة: حتى مع تصعيد 88.8% من الصور، الدقة القصوى 84.80%. السبب أن إجابات MobileNet «الواثقة» على الصور غير المقيدة أدق من العشوائية لكنها أدنى من Gemini — فكل صورة تُقبل محليًا تنقص الدقة قليلًا.
3. الثقة ضعيفة المعايير وغير رتيبة: شريحة 0.85–0.95 أعطت دقة 0.3333 — أدنى من شريحة 0.70–0.85 (0.3913). أي أن الاعتماد على الثقة كمؤشر صحة غير موثوق خارج توزيع التدريب، والفروقات بين الشرائح الوسطى ليست اتجاهًا ثابتًا.
4. الخلاصة العملية: لا يصح استخدام ثقة نموذج خارج نطاق تدريبه كآلية قرار تصعيد؛ النشر الواقعي إما خدمة سحابية كاملة (88.8% بدقة أعلى وكلفة سحابية) أو إعادة تدريب النموذج الخفيف على بيانات واقعية (المسار الموثق في الأعمال المستقبلية) — وأدوات هذا التحليل نفسها ستقيس التحسن بعد أي إعادة تدريب.

2) المرئيات الجديدة

ريونتل قداع مد ول قروصلا ن: تميقلا تلمسلم



شكل (1-2): سلسلة القيمة



شكل (2-2): المفاضلة الفعلية

الشكلان مقترح إدراجهما في الفصلين الرابع والسابع عند اعتماد النسخة النهائية المطبوعة.

(3) حزمة المراجعة الثانية (جاهزة للتنفيذ)

البروتوكول الكامل في 125 docs/second_reviewer_protocol.md: صورة مرقمة -R001

R125 بترتيب مخلوط ($seed=42$) وبلا أي تسمية ظاهرة — 7 أوراق معاينة عمياء + ورقة قرارات فارغة. يراجع شخص مختلف عن المُسمّي الأساسي بتعريفات الفئات الست، ثم يُحسب الاتفاق الخام وCohen's Kappa ويُدرج في موثوقية الوسوم. المطلوب: 45-60 دقيقة من مراجع بشري واحد.

(4) الاستبيان المصغر (جاهز للنشر)

سنة أسئلة جاهزة للصق في Google Forms في docs/mini_survey.md — مجهول الهوية، أقل من دقيقة للتعبئة، بتصريح صريح بأنها عينة ملائمة من 15-30 طالبًا لسياق الفرز الجامعي. التحليل الوصفي (نسب + رسوم) يُنفذ آليًا بعد إغلاق النموذج.

(5) الملفات المضافة والمعدلة

النوع	الملف
جديد — تحليل المهجين والمعايرة	scripts/analyze_hybrid.py
جديد — النتائج الفعلية الكاملة	results/webset/hybrid_analysis.json

الملف	النوع
charts/hybrid_policy_curve.png + charts/confidence_calibration.png	جديد — رسوم التحليل
scripts/make_figures.py + charts/topic_chain.png + charts/tradeoff.png	جديد — المرئيات
docs/second_reviewer_protocol.md + /review_web/blind	جديد — حزمة المُقيّم الثاني
docs/mini_survey.md	جديد — الاستبيان المصغر
docx / .pdf. تقرير_التحسينات	جديد — هذا التقرير
docx/pdf. بحث_فرز_المخلفات_بالذكاء_الاصطناعي	لم يُعدل — إدراج نتائج المهجين فيه ينتظر قرار الاعتماد

(6) ما لم يُنفذ ولماذا

1. المراجعة الثانية: تتطلب شخصًا بشريًا مختلفًا عن المُسمّي الأساسي — البروتوكول والمواد جاهزة والمتبقي 45-60 دقيقة مراجعة.
2. جمع ردود الاستبيان: يتطلب توزيع النموذج على طلاب حقيقيين — النموذج جاهز.
3. إدراج النظام المهجين في متن البحث: مؤجل لقرار الاعتماد بعد عرض النتائج الحقيقية أعلاه — النتيجة (تحسن كبير + ثقة غير موثوقة) مفيدتان علميًا أيًا كان القرار.